회의록

날짜	2026-10-30 (금)	시간	17:08 ~ 19:40
장소	카카오톡 (온라인)	작성자	강기민
참석자	강기민, 연승현		
목적(목표)	회사 제공 UI 프로토타입(HTML) 활용 방침에 따른 개발 범위 재설정, 분야별 역할 및 연동 방식 확정		
주제	산학공동프로젝트 개발 범위 재협의 (UI, DB, 서버, AI)		
회의 내용	**1. 개발 범위** - 기준 : 프로토타입에 없는 우리 설계가 화면에서 보이는 것 중심 - UI : 프로토타입 기반 제작, 담당자 페이지 집중 보강 - 민원 사이트 : 빠른 대강 구현, RAG, LLM 우선 - 화면 표시 항목 : AI 작성 / 담당자 수정 답변 구분, 답변 수정 기록 보기, AI 작업 진행 상태 보기 **2. DB** - 테이블 : 기존 설계 17개 → 8개 내외 대폭 축소, 샘플 데이터 추가 - 프로토타입 예시 민원 : 화면 목록, 상세 표시 용도 한정 - AI 응답 : 승현 측 모델, 검색 생성, DB 저장 후 화면 표시 - 목업 민원 : 모델 질문 생성 방식으로 변경 **3. 모델, RAG** - 임베딩 모델 : 예제의 all-MiniLM-L6-v2 대신 다국어 모델 검토, BAAI/bge-m3 후보 (GPU 8GB 이상 필요 의견, 양자화, 오프로딩 추가 확인 필요) - LLM : 카나나(성능 낮음), 솔라(VRAM 약 100GB) 제외, Qwen 계열 다국어 모델 선택 - 목표 사양 : q6 양자화, 컨텍스트 128k ~ 191k 적재 - 컨텍스트 관리 : prefix 캐싱 → 랭체인 → LLMLingua 순 시도, 하네스 지침 compact 제외 방안 논의 - 하네스 : llama.cpp 모델 서버 우선 구축, 이후 하네스 문서 작성 **4. 서버, 연동** - 서버, API : 승현 담당 (민원 등록, 목록 보기, 답변 올리기 중심) - 연동 방식 : MCP 제작 대신 API 호출, hermes에서 curl로 민원 게시판 서버 API 호출 - 용어 정리 : API = 외부 모델 API가 아닌 민원 게시판 서버 API		
결론 및 합의	- 역할 분담 : 기민 / UI와 DB, 승현 / 서버와 AI - UI : 프로토타입 기반, 담당자 페이지 중심 - 연동 : API 호출(curl) 방식 채택, MCP 미채택 - 목업 민원 : 모델 생성 방식 - LLM : Qwen 계열 다국어 모델 사용		
할 일	- DB 스키마(SQL) 초안 작성 완료(schema.sql), 공유 예정 - 목업 민원 데이터 형식 정리, curl용 API 목록 초안 작성 - 프로토타입 담당자 화면 수정 지점 확인, DB 설계 자료 8개 테이블 기준 수정 - llama.cpp 모델 서버 구축, 하네스 문서 작성 - 임베딩 모델 선정, 목업 민원 생성, 서버, API 구현		
참고 사항	- 프로젝트 마감 : 2026-11-27 - 미결 사항 : 임베딩 모델 최종 선정, DB 실행 위치, API 목록 확정 - LLM 모델명 : 대화 기재 기준 qwen 3.8 27b multilingual mtp		